


Rectified Flow 通过将一个平滑连接噪声与数据的插值过程"因果化"（或称为校正）来学习常微分方程 (ODE) 生成模型。该过程自然倾向于产生更直的轨迹，从而使得快速的欧拉离散化成为可能，并且这一过程可以重复进行，以进一步提高轨迹的直性。

目录

- 概述
- 问题：学习流生成模型
- Rectified Flow
- Reflow


概述




对于生成类任务来说，本质上是从一个采样的分布 $p_{base}(z)$ （文中为 π_0 ）经过一个生成模型（ G_{θ} ）转换到一个新的分布 $p_{\theta}(x)$ （文中为 π_1 ）的过程。

如果对于生成任务， π_0 可以从一个已知的分布（例如高斯分布）进行采样，对于新的分布（ π_1 ）我们不一定能够简单用数学描述，但可以从大量从 π_1 中采样的样本进行模拟。

- A generator G is a network. The network defines a probability distribution p_G



回顾 DDPM



那么我们看到 DDPM 在预测的时候是一步步生成从 Z_0 （通常要 20 - 1000 步）逼近 Z_1 ，那么自然的想法就是如何更快地生成呢？



最直观的想法当然是走直线最快，如果我们使用的是预测速度的 v -prediction 方式，那么只有在路径为直线时，一步生成式没有误差的，其他路径逼近都有误差。


Rectified Flow，一个“简简单单走直线”生成模型，是我们对这些挑战的一个回答：极度简单，一步生成。我们的方法有以下要点：

(1) 我们无需一般扩散模型复杂的推导，代之以一个简单的“沿直线生成”的思想。算法理解上不需要变分法或随机微分方程等基础知识。我们的方法是基于一个简单的常微分方程(ODE)，通过构造一个“尽量走直线”的连续运动系统来产生想要的分布。

(2) “尽量走直线”的目的是让我们模型实现快速生成。通过一个叫“reflow”的方法，我们可以实现梦想中的“一步生成”：只需一步计算就直接产生高质量的结果，而不需要调用计算量大的数值求解器来迭代式地模拟整个扩散过程。

(3) 通常的扩散模型是把高斯白噪声转换成想要的分布(比如图片)。我们的方法可以把任何一种数据或噪声(比如猫脸照片)转换成另外一种数据(比如人脸照片)。所以我们的方法不仅可以做生成模型，还可以应用于很多更广泛的迁移学习(比如domain transfer) 任务上。

问题定义：学习流生成模型



问题定义

无论是生成类问题（Generative Models）还是风格迁移类问题（Domain Transfer），都是一个分布到另一个分布的转化，因此可以看作是一个传输问题：

给定从两个分布中的采样 π_0 和 π_1 我们希望找到一个传输映射 T 使得当 $Z_0 \sim \pi_0$ 时， $Z_1 = T(Z_0) \sim \pi_1$ 。

生成建模可以被表述为寻找一种计算过程，将一个噪声分布（记作 π_0 ）转化为一个通过数据观察到的未知数据分布 π_1 。在流模型中，这个过程由常微分方程 (ODE) 表示：

$$\dot{Z}_t = v_t(Z_t), \quad \forall t \in [0, 1], \quad \text{starting from } Z_0 \sim \pi_0 \quad (1)$$

积分形式就是：

$$Z_t = Z_0 + \int_0^t v_s(Z_s, s) ds, \quad \forall t \in [0, 1], \quad Z_0 = X_0$$

其中 $\dot{Z}_t = \frac{dZ_t}{dt}$ 表示时间导数，而速度场 $v_t(x) = v(x, t)$ 是一个待学习的函数，其目的是确保从 $Z_0 \sim \pi_0$ 出发时，通过公式 $Z_1 = Z_0 + \int_0^1 v_t(Z_t, t) dt$ 积分到 Z_1 能够遵循目标分布 $Z_1 \sim \pi_1$ 。在这种情况下，我们称随机过程 $Z = \{Z_t\}$ 提供了从 π_0 到 π_1 的 (ODE) 传输。

需要注意的是，除平凡情况外，只要存在至少一种这样的传输，就会有无限多种 ODE 传输从 π_0 到 π_1 。因此，明确我们应当偏好哪种类型的 ODE 非常关键。

一种选择是偏好那些在推理时易于求解的 ODE。实际上，ODE 通常通过数值方法进行近似求解，这些方法通常构造 ODE 轨迹的分段线性近似。例如，一个常见的数值方法选择是欧拉方法 (Eular method, 当然还有 RK4 等方法)：

$$\hat{Z}_{t+\epsilon} = \hat{Z}_t + \epsilon v_t(\hat{Z}_t), \quad \forall t \in \{0, \epsilon, 2\epsilon, \dots, 1\} \quad (2)$$

其中 $\epsilon > 0$ 是步长。调整步长 ϵ 会在精度和计算成本之间构成权衡：较小的 ϵ 能提高精度，但需要更多的计算步骤。因此，我们应追求那些即便在较大步长下也能精确近似的 ODE。




图1. Lady Windermere's fan 图示了欧拉方法轨迹的误差累积情况：不同初始点的轨迹随着时间偏离真实解曲线。



理想情况是当 ODE 轨迹完全为直线时，欧拉法可实现**零离散化误差**，而不受步长选择的影响。在这种情况下，经时间重参数化后，ODE 应满足：

$$Z_t = t Z_1 + (1 - t) Z_0, \quad \implies \quad \dot{Z}_t = Z_1 - Z_0$$

这些 ODE 被称为**直线传输**，它们能够实现可在一步内模拟的**快速生成模型**。我们将所得的对 (Z_0, Z_1) 称为 π_0 与 π_1 的直线耦合。尽管在实际中可能无法达到完美直线性，但我们可以尽量使 ODE 轨迹直，从而最大化计算效率。

耦合 (Coupling) 的作用 在概率论中，两个分布 π_0 和 π_1 的耦合是指它们的联合概率分布 $\gamma(x_0, x_1)$ ，满足：

$$\int \gamma(x_0, x_1) dx_1 = \pi_0(x_0), \quad \int \gamma(x_0, x_1) dx_0 = \pi_1(x_1)$$

即边缘分布分别为 π_0 和 π_1 。

在 Rectified Flow 中的意义

1. **轨迹构造基础** 耦合 $(X_0, X_1) \sim \gamma$ 定义了噪声样本 $X_0 \sim \pi_0$ 与数据样本 $X_1 \sim \pi_1$ 的配对关系，进而通过插值生成中间轨迹：

$$X_t = t X_1 + (1-t) X_0$$

\$\$

2. 影响ODE直线性 不同的耦合会导致不同的插值轨迹形态：

- 独立耦合： X_0 与 X_1 独立采样 ($\gamma = \pi_0 \times \pi_1$)，轨迹易交叉（图2a）
- 直线耦合：存在双射 $X_1 = F(X_0)$ ，使得所有轨迹为直线（理想情况）

关键耦合类型对比

耦合类型	数学形式	轨迹特性	生成效率
独立耦合	$\gamma = \pi_0 \times \pi_1$	多交叉，曲率大	低（需多步采样）
Straight耦合	$X_1 = X_0 + v(X_0)$	无交叉，完全直线	高（单步生成）
Rectified耦合	通过Reflow迭代优化	渐进直化，交叉减少	逐步提升

耦合优化的核心思想 Rectified Flow通过以下步骤优化耦合：

- 初始独立耦合：从独立样本对 (X_0, X_1) 开始
- 校正速度场：学习 $v_t^*(x) = \mathbb{E}[X_1 - X_0 \mid X_t = x]$
- 生成新耦合：通过ODE $\dot{Z}_t = v_t^*(Z_t)$ 得到 (Z_0, Z_1)
- 迭代直化：将 (Z_0, Z_1) 作为新耦合输入Reflow过程

示例：若初始耦合为独立分布，经过一次 Rectify 后，新耦合 (Z_0, Z_1) 满足：

\$\$ Z_1 = Z_0 + \int_0^1 v_t^*(Z_t) dt

\$\$

这种耦合的直线性显著优于初始独立耦合。

Rectified Flow

符号定义

原始耦合：

- X_0 ：初始分布 π_0 中的样本（比如高斯噪声）
- X_1 ：目标分布 π_1 中的样本（比如真实图像）

Rectified 耦合：

- Z_0 ：与 X_0 具有相同分布的新起点（比如重新在高斯噪声中采样）

- Z_1 ：通过 Rectified Flow 网络预测积分得到的新的对应于 Z_0 的终点

对于每一次迭代后的耦合对可以采用上标 k 表示，例如： Z_0^k 和 Z_1^k 。

二者的区别：原始耦合是随机的他们的路径可能交叉，Rectified 耦合之间的样本路径更直。

为了构造一个从 π_0 到 π_1 的流，假设我们获得了一个任意耦合 (X_0, X_1) （例如， $\pi_0 \times \pi_1$ 的独立耦合，这是当我们可以获取 π_0 和 π_1 独立样本时常见的情况）。基本思路是将 (X_0, X_1) 转换为由 ODE 模型生成的更优耦合。我们还可以选择性地重复这一过程，以进一步提升诸如直线性等目标属性。

Rectified Flow 的构造方法

Rectified Flow 的构造方法如下：

- 构建插值：

首先，构建一个插值过程 $\{X_t\} = \{X_t : t \in [0, 1]\}$ ，在 X_0 与 X_1 之间平滑过渡。虽然可以选择其它插值方式，但这里我们采用典型的直线插值：

$$X_t = t X_1 + (1 - t) X_0$$

这种插值过程 $\{X_t\}$ 是通过 "锚定-桥接" 方式生成的：首先采样端点 X_0 与 X_1 ，然后生成连接这两者的中间轨迹。

- 边际匹配：

通过上述构造，插值过程 $\{X_t\}$ 的端点 X_0 和 X_1 自然匹配目标分布 π_0 与 π_1 。但是， $\{X_t\}$ 并不是一个因果的 ODE 过程（比如 $\dot{Z}_t = v_t(Z_t)$ ），后者是通过从 Z_0 随时间前进生成 Z_1 。生成 X_t 则需要同时依赖 X_0 和 X_1 ，而非仅从 X_0 随 t 增加而演化。

- 速度场估计：

为了将插值过程转换为 ODE 流，我们需要使用神经网络学习一个速度场 v_t ，使得它能近似 X_t 的时间导数 $\dot{X}_t$ 。为此，我们求解如下优化问题：

$$\min_v \int_0^1 \mathbb{E} \left[\|\dot{X}_t - v(X_t, t)\|^2 \right] dt.$$

其中 v 通常使用深度神经网络（参数为 θ ）进行参数化，因此在后面证明时我们会标记为 v_θ ，期望项关于插值轨迹取样。当然在直线差值情况下：


$$\dot{X}_t = X_1 - X_0$$

符号说明。 一个随机过程 $X_t = X(t, \omega)$ 是关于时间 t 及随机种子 ω 的可测函数（随机种子的分布记作 $\mathbb{P}$ ）。在这里，端点 (X_0, X_1) 就构成了随机种子；而 $\dot{X}_t = \partial_t X(t, \omega)$ 是关于 t 的偏导数，同样依赖于同一随机种子。通常我们在书写时会省略随机种子的符号。

这一优化问题的最优解为条件均值（我们需要证明的部分，证明1）：

$$v_t^*(x) = \mathbb{E}[\dot{X}_t \mid X_t = x].$$

且在这种直线插值中，这一结果与 t 无关。



***图2.** 图中展示了从 π_0 到 π_1 的 Rectified Flow。蓝色和绿色轨迹表示不同模式的轨迹，便于可视化。*




图3：示意图 $v_t^*(x) = \mathbb{E}[X_1 - X_0 \mid X_t = x]$ 。

直观解释：

- 在插值过程 $\{X_t\}$ 中，不同轨迹可能相交，因而在某一点 X_t 处可能得到多个不同的 $\dot{X}_t$ 值（参见图2a）。
- 相比之下，在由 $\dot{Z}_t = v_t^*(Z_t)$ 定义的 ODE 中，每个点 Z_t 的更新方向是唯一确定的，这避免了交叉后方向分叉的情况。
- 所以，在交叉点处，ODE 通过采用条件均值 $v_t^*(x)$ 来"去随机化"更新方向，从而将各插值轨迹重构为不交叉的路径（参见图2b）。
- 由于 ODE 轨迹 $\{Z_t\}$ 不能相交，它们必须在潜在的交叉点处弯曲，以"重连"原始插值路径并避免交叉。

Reflow

尽管 Rectified Flow 倾向于生成更直的轨迹，但这些轨迹并不完全是直线。正如图2(a)所示，在插值轨迹的交叉点处，流仍可能发生转弯。那么，我们如何进一步提升流，使得轨迹更直，从而加速推理？

一个关键的见解是，Rectified Flow 生成的起止对 (Z_0, Z_1) （也称为 **Rectified Coupling**）相比原始耦合 (X_0, X_1) 更优、更"直"。这是因为如果我们用直线插值重新连接 Z_0 与 Z_1 ，那么得到的轨迹将交叉得更少。因此，通过基于重新插值耦合训练一个新的 Rectified Flow，我们能够进一步使轨迹直化，从而实现更快的采样推理。

形式上，我们递归应用 **Rectify**($\cdot$) 操作，从 $(Z_0^0, Z_1^0) = (X_0, X_1)$ 开始，得到一系列 Rectified Flow：

$$\text{Reflow: } \{Z_t^{k+1}\} = \text{Rectify}(\text{Interp}(Z_0^k, Z_1^k)),$$

其中 $\text{Interp}(Z_0^k, Z_1^k)$ 表示利用 (Z_0^k, Z_1^k) 构造的插值过程。我们将 $\{Z_t^k\}$ 称为第 k 个 Rectified Flow，简称为 **k -Rectified Flow**，它是由 (X_0, X_1) 诱导得到的。

这一 Reflow 过程被证明在以下意义上能使轨迹更直。我们定义流的直性量度为

$$S(\{Z_t\}) = \int_0^1 \mathbb{E} \left[\|Z_1 - Z_0 - \dot{Z}_t\|^2 \right] dt,$$

其中 $S(\{Z_t\}) = 0$ 表示轨迹完全为直线。研究表明，

$$\mathbb{E}_{k \sim \text{Unif}(\{1, \dots, K\})} \left[S(\{Z_t^k\}) \right] = \mathcal{O}\left(\frac{1}{K}\right)$$

这意味着在前 K 次迭代中，直性量度的平均值以 $\mathcal{O}(1/K)$ 的速率衰减。

需要注意的是，Reflow 可以从任一耦合 (X_0, X_1) 开始，因此它提供了一种普适的直化（加速）方法，同时保留边际分布不变。

Reflow 与捷径学习。 直观上，Reflow 类似于人类的捷径学习：一旦首次解决了某个问题，我们便学会了直接走捷径，从而在下一次能够更快地得到解答。

整体流程

Rectified Flow 算法

基于上述理论，我们可以总结 Rectified Flow 的训练和采样算法：

算法 1: Rectified Flow 训练

1. 输入：从 π_0 和 π_1 中采样的数据对 (X_0, X_1)
2. 对每个训练步骤：
 - 随机采样时间点 $t \sim \text{Uniform}(0, 1)$
 - 计算插值点 $X_t = tX_1 + (1 - t)X_0$
 - 更新速度场网络 v_θ 以最小化损失 $\mathbb{E}[\|X_1 - X_0 - v_\theta(X_t, t)\|^2]$
3. 输出：训练好的速度场网络 v_θ

算法 2: Rectified Flow 采样

1. 输入：训练好的速度场 v_θ ，采样点 $Z_0 \sim \pi_0$ ，步长 ϵ
2. 初始化 $Z_0 \sim \pi_0$
3. 对 $t = 0, \epsilon, 2\epsilon, \dots, 1 - \epsilon$ 执行：
 - 更新 $Z_{t+\epsilon} = Z_t + \epsilon \cdot v_\theta(Z_t, t)$
4. 输出：生成样本 $Z_1 \sim \pi_1$

理论分析

在 Rectified Flow 中，我们学习到的 ODE 流 $\{Z_t\}$ 具有以下重要性质：

1. **边际保持**：对于任意 $t \in [0, 1]$ ，如果 $Z_0 \sim \pi_0$ ，那么 Z_t 的分布与 X_t 的分布相同，特别是 $Z_1 \sim \pi_1$ 。
2. **轨迹直线化**：与原始插值轨迹 $\{X_t\}$ 相比，ODE 流 $\{Z_t\}$ 的轨迹更接近直线，这使得数值求解更高效。

这些性质使 Rectified Flow 成为一种有效的生成模型方法，特别是当我们需要快速生成样本时。

图3. 左图：独立耦合下的直线插值轨迹，轨迹交叉严重。右图：经过 Rectified Flow 优化后的轨迹，更接近直线且交叉减少。

Reflow：通过迭代提高直线性

尽管 Rectified Flow 已经能够产生比原始插值更直的轨迹，但我们可以通过一个称为 **Reflow** 的迭代过程进一步提高轨迹的直线性。

流的直线性度量

为了量化流的直线性，我们定义以下度量：

$$S(Z_t) = \mathbb{E} \left[\int_0^1 \left\| \frac{dZ_t}{dt} - (Z_1 - Z_0) \right\|^2 dt \right] \quad (12)$$

当 $S(Z_t) = 0$ 时，流完全由直线组成。

Reflow 算法

Reflow 的核心思想是将一个流的输出作为下一个流的输入，通过迭代提高直线性：

算法 3: Reflow 迭代

1. 初始化：设置初始流 $Z^{(0)} = X$ （即直线插值）
2. 对 $k = 1, 2, \dots, K$ 执行：
 - 学习速度场 $v^{(k)}$ 以拟合 $Z^{(k-1)}$ 的时间导数
 - 使用 $v^{(k)}$ 生成新流 $Z^{(k)}$
3. 输出：最终流 $Z^{(K)}$

理论上可以证明，随着迭代次数增加，流的直线性单调提高：

$$S(Z^{(k+1)}) \leq S(Z^{(k)}), \quad \forall k \geq 0 \quad (13)$$


并且在理想情况下，当 $k \rightarrow \infty$ 时， $S(Z^{(k)}) \rightarrow 0$ ，即流趋向于完全由直线组成。

一步采样

Reflow 的一个重要应用是实现"一步采样"。当流足够直时，我们可以使用一个大步长 ($\epsilon = 1$) 直接从 Z_0 生成 Z_1 ：

$$Z_1 \approx Z_0 + v_1(Z_0, 0) \quad (14)$$

这大大加速了生成过程，使得 Rectified Flow 在实际应用中更具吸引力。



Syntax error in graph mermaid version 8.14.0

实验效果




图5：1-Rectified Flow 与 2-Rectified Flow

理论推导

证明1：条件期望是优化目标最优解

在本节中，我们将严格证明为什么优化目标：

$$\mathbb{E}_{x_0 \sim \pi_0, x_1 \sim \pi_1} \left[\left\| v_\theta(x_t, t) - \frac{\partial}{\partial t} \varphi_t(x_0, x_1) \right\|^2 \right]$$

会导出最优速度场 $v_t^*(x) = \mathbb{E}[\dot{X}_t \mid X_t = x]$ ，从而构建满足所需边际分布的ODE：

$$\frac{dx_t}{dt} = v_t^*(x_t)$$

基本假设

- 假设存在轨迹 $x_t = \varphi_t(x_0, x_1)$ ，这对应于我们的直线插值 $X_t = tX_1 + (1 - t)X_0$
- 假设该轨迹关于 x_1 是可逆的，即可以解出 $x_1 = \psi_t(x_0, x_t)$

期望表达式推导

从测试函数的角度开始分析。给定任意光滑测试函数 ϕ ，考虑其在时间 $t + \Delta t$ 处的期望：

$$\mathbb{E}_{x_{t+\Delta t}}[\phi(x_{t+\Delta t})] = \mathbb{E}_{x_0, x_1}[\phi(\varphi_{t+\Delta t}(x_0, x_1))]$$

通过泰勒展开到一阶：

$$\mathbb{E}_{x_0, x_1} \left[\phi(\varphi_t(x_0, x_1)) + \Delta t \frac{\partial \varphi_t(x_0, x_1)}{\partial t} \cdot \nabla_{\varphi_t} \phi(\varphi_t(x_0, x_1)) \right] + o(\Delta t)$$

这可以重写为：

$$\mathbb{E}_{x_0, x_1}[\phi(x_t)] + \Delta t \mathbb{E}_{x_0, x_1} \left[\frac{\partial \varphi_t(x_0, x_1)}{\partial t} \cdot \nabla_{x_t} \phi(x_t) \right] + o(\Delta t)$$

注意到 $x_t = \varphi_t(x_0, x_1)$ ，上式可表示为：

$$\mathbb{E}_{x_t}[\phi(x_t)] + \Delta t \mathbb{E}_{x_0, x_t} \left[\frac{\partial \varphi_t(x_0, x_1)}{\partial t} \cdot \nabla_{x_t} \phi(x_t) \right] + o(\Delta t)$$

条件期望引入

条件期望的性质说明：

在这一步中，我们使用了条件期望的以下关键性质：

1. **全期望公式 (Law of Total Expectation)**：对于任意随机变量 X 和 Y ，以及可积函数 g ，有

$$\mathbb{E}[g(X)] = \mathbb{E}[\mathbb{E}[g(X)|Y]]$$

\$\$

\$. **条件期望的线性性**：对于随机变量 X 、 Y 和函数 g_1 、 g_2 ，有

\$\$

$$\mathbb{E}[a g_1(X) + b g_2(X)|Y] = a\mathbb{E}[g_1(X)|Y] + b\mathbb{E}[g_2(X)|Y]$$

\$. **条件期望与确定性变量的分离**：若 $h(Y)$ 是 Y 的函数，则

\$\$

$$\mathbb{E}[h(Y)g(X)|Y] = h(Y)\mathbb{E}[g(X)|Y]$$

\$\diamond\diamond\$我们的推导中，将 $\mathbb{E}_{x_0, x_t}[\frac{\partial \varphi_t}{\partial t} \cdot \nabla \phi(x_t)]$ 改写为条件期望形式时，我们应用了上述性质：

- 首先，注意到 $\nabla_{x_t} \phi(x_t)$ 只依赖于 x_t ，因此在给定 x_t 的条件下是确定的
- 应用性质3，可将其从条件期望中分离出来：

\$\$

$$\mathbb{E}_{x_0, x_t}[\frac{\partial \varphi_t}{\partial t} \cdot \nabla \phi(x_t)] = \mathbb{E}_{x_t}[\mathbb{E}_{x_0|x_t}[\frac{\partial \varphi_t}{\partial t}]] \cdot \nabla \phi(x_t)$$

\$这一变换是推导ODE形式的关键步骤，它使我们能够将条件期望 $\mathbb{E}_{x_0|x_t}[\frac{\partial \varphi_t}{\partial t}]$ 识别为最优速度场。

\$\$

利用条件期望的性质，可以将表达式改写为：

$$\mathbb{E}_{x_t}[\phi(x_t)] + \Delta t \mathbb{E}_{x_t} \left[\mathbb{E}_{x_0|x_t} \left[\frac{\partial \varphi_t(x_0, x_1)}{\partial t} \right] \cdot \nabla_{x_t} \phi(x_t) \right] + o(\Delta t)$$

根据泰勒展开的逆向应用，这等价于：

$$\mathbb{E}_{x_t} \left[\phi \left(x_t + \Delta t \mathbb{E}_{x_0|x_t} \left[\frac{\partial \varphi_t(x_0, x_1)}{\partial t} \right] \right) \right] + o(\Delta t)$$

ODE 推导

由于上述等式对任意测试函数 ϕ 成立，我们可以得到：

$$x_{t+\Delta t} \approx x_t + \Delta t \mathbb{E}_{x_0|x_t} \left[\frac{\partial \varphi_t(x_0, x_1)}{\partial t} \right]$$

当 $\Delta t \rightarrow 0$ 时，这正是如下ODE：

$$\frac{dx_t}{dt} = \mathbb{E}_{x_0|x_t} \left[\frac{\partial \varphi_t(x_0, x_1)}{\partial t} \right]$$

对于线性插值 $\varphi_t(x_0, x_1) = tx_1 + (1-t)x_0$ ，我们有 $\frac{\partial \varphi_t}{\partial t} = x_1 - x_0$ ，因此：

$$\frac{dx_t}{dt} = \mathbb{E}_{x_0|x_t} [x_1 - x_0] = v_t^*(x_t)$$

最优解证明

根据期望的性质：

$$\mathbb{E}[X] = \arg \min_{\mu} \mathbb{E}[\|X - \mu\|^2]$$

这表明条件期望 $\mathbb{E}_{x_0|x_t} [\frac{\partial \varphi_t}{\partial t}]$ 正是优化目标：

$$\min_v \mathbb{E} \left[\left\| \frac{\partial \varphi_t}{\partial t} - v(x_t, t) \right\|^2 \right]$$

的最优解。换言之，当 $v_\theta(x, t)$ 逼近条件期望 $\mathbb{E}[\dot{X}_t | X_t = x]$ 时，我们的学习会得到最优结果。这正是前述最优速度场的理论依据：

$$v_t^*(x) = \mathbb{E}[X_1 - X_0 | X_t = x]$$

引用自原文：[Rectified Flow: Straight is Fast](#)

条件期望与确定性变量的分离

性质表述

在条件期望与确定性变量的分离性质中：

$$\mathbb{E}[h(Y)g(X)|Y] = h(Y)\mathbb{E}[g(X)|Y] \tag{17}$$

这里的 $\mathbb{E}[\cdot|Y]$ 表示在给定随机变量 Y 的条件下的期望。具体来说：

- 这是对随机变量 X 的条件分布 $P(X|Y)$ 计算的期望
- $h(Y)$ 是 Y 的函数
- $g(X)$ 是 X 的函数

推导过程

这个性质的推导基于条件期望的基本定义。对于连续随机变量，条件期望定义为：

$$\mathbb{E}[Z|Y = y] = \int z \cdot f_{Z|Y}(z|y)dz \quad (18)$$

其中 $f_{Z|Y}(z|y)$ 是在 $Y = y$ 条件下 Z 的条件概率密度函数。

现在，让我们考虑 $Z = h(Y)g(X)$ ，即我们想求 $\mathbb{E}[h(Y)g(X)|Y = y]$ ：

$$\mathbb{E}[h(Y)g(X)|Y = y] = \int h(Y)g(x) \cdot f_{X|Y}(x|y)dx \quad (19)$$

由于在条件 $Y = y$ 下， $h(Y)$ 是一个确定的值 $h(y)$ （不再是随机变量），所以它可以从积分中提出来：

$$\mathbb{E}[h(Y)g(X)|Y = y] = h(y) \int g(x) \cdot f_{X|Y}(x|y)dx = h(y) \cdot \mathbb{E}[g(X)|Y = y] \quad (20)$$

这就得到了 $\mathbb{E}[h(Y)g(X)|Y = y] = h(y)\mathbb{E}[g(X)|Y = y]$ 。

将 $Y = y$ 推广到随机变量 Y ，我们得到：

$$\mathbb{E}[h(Y)g(X)|Y] = h(Y)\mathbb{E}[g(X)|Y] \quad (21)$$

在我们的推导中的应用

在公式 (6) 到 (7) 的转换中，我们使用了这个性质：

从：

$$\mathbb{E}_{x_t}[\phi(x_t)] + \Delta t \mathbb{E}_{x_0, x_1 | x_t} \left[\frac{\partial \varphi_t(x_0, x_1)}{\partial t} \cdot \nabla_{x_t} \phi(x_t) \right] + o(\Delta t) \quad (6)$$

到：

$$\mathbb{E}_{x_t}[\phi(x_t)] + \Delta t \mathbb{E}_{x_t} \left[\mathbb{E}_{x_0 | x_t} \left[\frac{\partial \varphi_t(x_0, \psi_t(x_0, x_t))}{\partial t} \right] \cdot \nabla_{x_t} \phi(x_t) \right] + o(\Delta t) \quad (7)$$

这里：

- Y 对应于 x_t
- X 对应于 x_0 （注意 x_1 可以通过 x_0 和 x_t 确定为 $\psi_t(x_0, x_t)$ ）
- $h(Y)$ 对应于 $\nabla_{x_t} \phi(x_t)$ ，它只依赖于 x_t

- $g(X)$ 对应于 $\frac{\partial \varphi_t(x_0, \psi_t(x_0, x_t))}{\partial t}$

因此，在给定 x_t 的条件下， $\nabla_{x_t} \phi(x_t)$ 是一个确定的值，可以从条件期望中提出来，得到：

$$\mathbb{E}_{x_0, x_1 | x_t} \left[\frac{\partial \varphi_t(x_0, x_1)}{\partial t} \cdot \nabla_{x_t} \phi(x_t) \right] = \nabla_{x_t} \phi(x_t) \cdot \mathbb{E}_{x_0 | x_t} \left[\frac{\partial \varphi_t(x_0, \psi_t(x_0, x_t))}{\partial t} \right] \quad (22)$$

这正是我们在推导中使用的条件期望与确定性变量分离的性质。

证明1：最优解证明中的期望性质解析（备份）

在最优解证明过程中，我们使用了期望的一个重要性质，我来详细解释这个性质及其在证明中的应用。

期望的线性性质

期望的线性性质是指：对于随机变量 X 和 Y ，以及常数 a 和 b ，有：

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$$

这个性质可以扩展到任意有限个随机变量的线性组合。

在最优解证明中的应用

在最优解证明中，我们需要最小化以下形式的期望：

$$\mathbb{E}_{x_0, x_1, x_t} \left[\left\| \frac{\partial \varphi_t(x_0, x_1)}{\partial t} - s_\theta(x_t, t) \right\|^2 \right]$$

展开平方项，我们得到：

$$\mathbb{E}_{x_0, x_1, x_t} \left[\left\| \frac{\partial \varphi_t(x_0, x_1)}{\partial t} \right\|^2 - 2 \left\langle \frac{\partial \varphi_t(x_0, x_1)}{\partial t}, s_\theta(x_t, t) \right\rangle + \|s_\theta(x_t, t)\|^2 \right]$$

根据期望的线性性质，上式等于：

$$\mathbb{E}_{x_0, x_1, x_t} \left[\left\| \frac{\partial \varphi_t(x_0, x_1)}{\partial t} \right\|^2 \right] - 2\mathbb{E}_{x_0, x_1, x_t} \left[\left\langle \frac{\partial \varphi_t(x_0, x_1)}{\partial t}, s_\theta(x_t, t) \right\rangle \right] + \mathbb{E}_{x_0, x_1, x_t} \left[\|s_\theta(x_t, t)\|^2 \right]$$

全期望公式的应用

接下来，我们应用全期望公式处理第二项：

$$\mathbb{E}_{x_0, x_1, x_t} \left[\left\langle \frac{\partial \varphi_t(x_0, x_1)}{\partial t}, s_\theta(x_t, t) \right\rangle \right] = \mathbb{E}_{x_t} \left[\mathbb{E}_{x_0, x_1 | x_t} \left[\left\langle \frac{\partial \varphi_t(x_0, x_1)}{\partial t}, s_\theta(x_t, t) \right\rangle \right] \right]$$

条件期望与确定性变量分离

由于 $s_\theta(x_t, t)$ 只依赖于 x_t 和 t ，在给定 x_t 的条件下，它是一个确定的值。根据条件期望与确定性变量分离的性质，我们有：

$$\mathbb{E}_{x_0, x_1 | x_t} \left[\left\langle \frac{\partial \varphi_t(x_0, x_1)}{\partial t}, s_\theta(x_t, t) \right\rangle \right] = \left\langle \mathbb{E}_{x_0, x_1 | x_t} \left[\frac{\partial \varphi_t(x_0, x_1)}{\partial t} \right], s_\theta(x_t, t) \right\rangle$$

这里使用了内积的线性性质和条件期望的性质。

最优解的推导

当我们要最小化上述期望表达式时，只有第二项和第三项包含了我们的优化目标 $s_\theta(x_t, t)$ 。第一项是一个常数，与 s_θ 无关。

为了最小化整个表达式，我们需要：

1. 最大化第二项： $2\mathbb{E}_{x_0, x_1, x_t} \left[\left\langle \frac{\partial \varphi_t(x_0, x_1)}{\partial t}, s_\theta(x_t, t) \right\rangle \right]$
2. 最小化第三项： $\mathbb{E}_{x_0, x_1, x_t} \left[\|s_\theta(x_t, t)\|^2 \right]$

根据上面的推导，最优的 $s_\theta(x_t, t)$ 应该等于：

$$s_\theta^*(x_t, t) = \mathbb{E}_{x_0, x_1 | x_t} \left[\frac{\partial \varphi_t(x_0, x_1)}{\partial t} \right]$$

这个结果可以通过变分法或直接对 $s_\theta(x_t, t)$ 求导并令其等于零来证明。

总结

在最优解证明中，我们主要使用了以下期望性质：

1. 期望的线性性质： $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$
2. 全期望公式： $\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|Y]]$
3. 条件期望与确定性变量分离： $\mathbb{E}[h(Y)g(X)|Y] = h(Y)\mathbb{E}[g(X)|Y]$

4. 内积的线性性质: $\langle a + b, c \rangle = \langle a, c \rangle + \langle b, c \rangle$

这些性质共同帮助我们推导出了最优的分数匹配模型 $s_\theta^*(x_t, t)$ 。

证明2: 边缘分布保持性质

边缘分布保持性质指的是: 对于 $\forall t$, $Law(Z_t) = Law(X_t)$ 是非线性整流流在(6)中的一般性质, 无论插值过程 X_t 是否为直线 [3]。

定义 3.1 对于一个路径连续可微的随机过程 $X = \{X_t : t \in [0, 1]\}$, 其期望速度 v^X 定义为:

$$v^X(x, t) = \mathbb{E}[\dot{X}_t | X_t = x], \quad \forall x \in \text{supp}(X_t)$$

对于 $x \notin \text{supp}(X_t)$, 条件期望未定义, 我们任意设定 $v^X(x, t) = 0$ 。

定义 3.2 如果 v^X 是局部有界的, 且下面的积分方程存在唯一解, 我们称 X 是可整流的:

$$Z_t = Z_0 + \int_0^t v^X(Z_s, s) ds, \quad \forall t \in [0, 1], \quad Z_0 = X_0$$

在这种情况下, $Z = \{Z_t : t \in [0, 1]\}$ 被称为由 X 诱导的整流流。

定理 3.3 假设 X 是可整流的, Z 是其整流流。则对所有 $t \in [0, 1]$ 有: $Law(Z_t) = Law(X_t)$ 。

证明 对于任意紧支撑的连续可微测试函数 $h : \mathbb{R}^d \rightarrow \mathbb{R}$, 我们有:

$$\frac{d}{dt} \mathbb{E}[h(X_t)] = \mathbb{E}[\nabla h(X_t)^T \dot{X}_t] = \mathbb{E}[\nabla h(X_t)^T v^X(X_t, t)]$$

这里我们用到了 $v^X(X_t, t) = \mathbb{E}[\dot{X}_t | X_t]$ 。根据定义, 这等价于 $\pi_t := Law(X_t)$ 在分布意义下求解具有漂移 $v_t^X := v^X(\cdot, t)$ 的连续性方程:

$$\dot{\pi}_t + \nabla \cdot (v_t^X \pi_t) = 0$$

要看到(10)和(11)的等价性, 我们可以将(11)两边乘以 h 并积分:

$$\begin{aligned} 0 &= \int h(\dot{\pi}_t + \nabla \cdot (v_t^X \pi_t)) \\ &= \int h \dot{\pi}_t - \nabla h^T v_t^X \pi_t \\ &= \frac{d}{dt} \mathbb{E}[h(X_t)] - \mathbb{E}[\nabla h(X_t)^T v^X(X_t, t)] \end{aligned}$$

这里我们用到了分部积分：

$$\int h \nabla \cdot (v_t^X \pi_t) = - \int \nabla h^T (v_t^X \pi_t)$$

因为 Z_t 由相同的速度场 v^X 驱动，其边缘分布 $Law(Z_t)$ 求解相同的方程且具有相同的初始条件 ($Z_0 = X_0$)。因此，如果方程(11)的解是唯一的， $Law(Z_t)$ 和 $Law(X_t)$ 的等价性就成立了。而(11)解的唯一性等价于 $dZ_t = v^X(Z_t, t)dt$ 解的唯一性，这可以由 Kurtz [37] 的推论 1.3 得到（另见 Ambrosio 和 Crippa [1] 的定理 4.1）。

第二步是利用向量函数求导的性质。原始的性质是复合函数的链式法则，适用于标量函数对向量的求导。

具体来说，对于复合函数 $h(X_t)$ ，其中 $h: \mathbb{R}^d \rightarrow \mathbb{R}$ 是标量函数， $X_t: \mathbb{R} \rightarrow \mathbb{R}^d$ 是向量值函数，复合函数对时间 t 的导数遵循以下链式法则：

$$\frac{d}{dt} h(X_t) = \sum_{i=1}^d \frac{\partial h(X_t)}{\partial (X_t)_i} \cdot \frac{d(X_t)_i}{dt}$$

这可以用向量形式更简洁地表示为：

$$\frac{d}{dt} h(X_t) = \nabla h(X_t)^\top \dot{X}_t$$

其中：

- $\nabla h(X_t)$ 是函数 h 在点 X_t 处的梯度，即 $\nabla h(X_t) = \left(\frac{\partial h}{\partial x_1}, \frac{\partial h}{\partial x_2}, \dots, \frac{\partial h}{\partial x_d} \right)^\top$ 在 X_t 处的值
- $\dot{X}_t = \frac{dX_t}{dt}$ 是向量 X_t 对时间 t 的导数